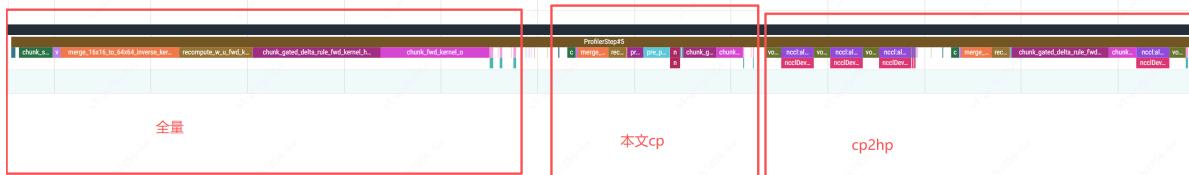


GDN和KDA的高效CP方法

全新的CP方法。基于前人的伟大博客[DeltaNet如何做序列并行](#)加上自己的理解进行实现，大大加速GDN (KDA) 在长文本下的训练效率，并且CP无限开，轻松训练到1M长度。目前已给flash-linear-attention 提了pr，欢迎大家尝试或者进行review。

GDN

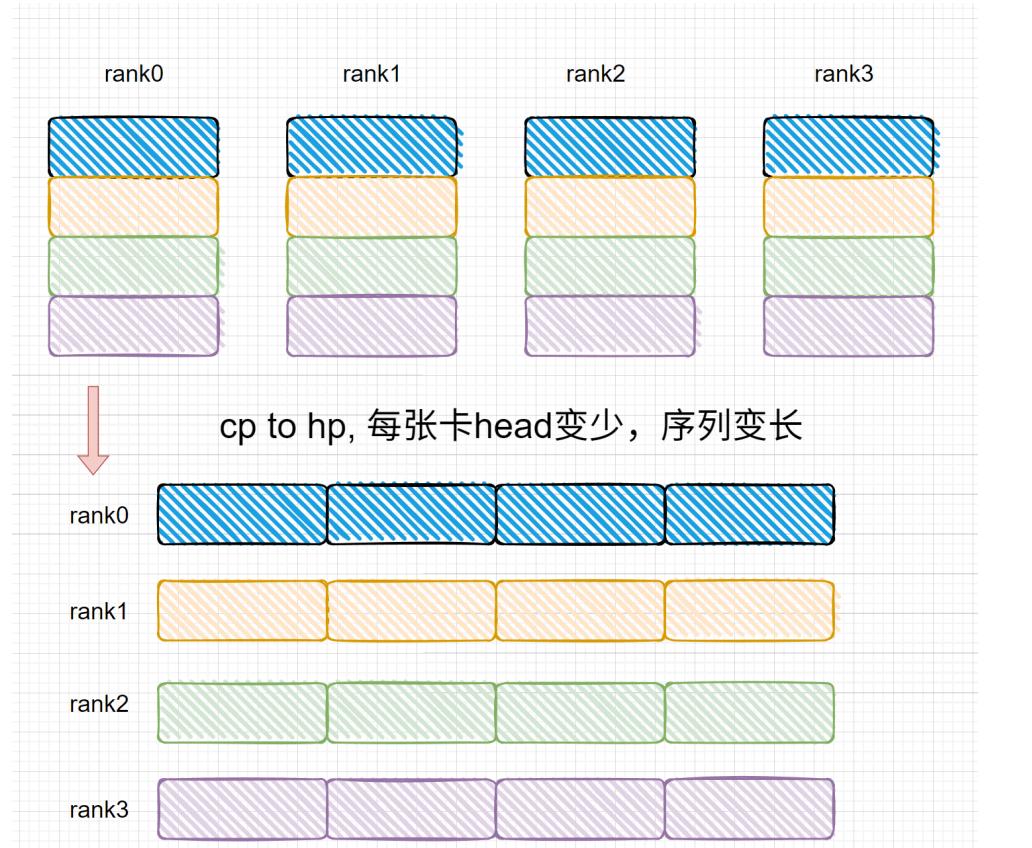


KDA



为什么需要更高效的CP

- GDN或KDA等linear attn是为解决长序列而存在的，面对长序列训练有两个基本要求：
 - 要能在足够长的序列上进行训练，即有可行的CP方案
 - 在长序列上训练性能不会严重裂化
- 现存CP方案
 - 目前GDN的CP方案开源出来的，我看到的很少，比如有[Megatron-LM dev](#)。丰富程度远不如 MHA/GQA等标准attention
 - Megatron-LM的实现、我自己之前的实现以及和其他人的讨论得知的方案，大家基本都是使用的cp2hp (**deepspeed-ulysses**) 的并行方式，因为算法本身就是在head维度进行并行，对head不感知，因此算子无需任何修改即可
 - ring attention (p2p) 或者 all-gather attention (llama3 cp)对GDN都不太兼容，因此无法使用



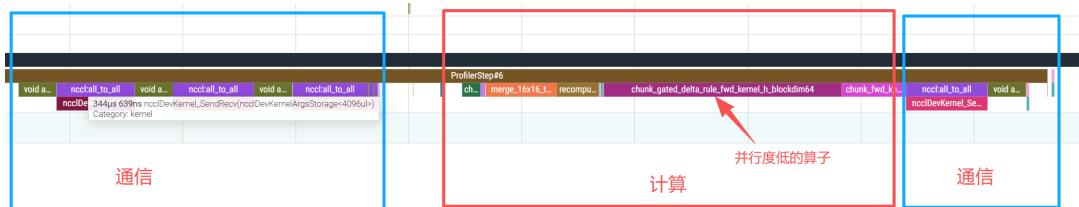
- cp2hp的不足

- 最大cp数量受限head个数。`max_cp_size = num_heads`。Kimi-linear报告中显示支持1M的context，该model只有32个head，如果是原生训练1M长度的话，把cp拉满，每张卡需要放64k长度的数据，这显然非常大了。因此我猜测可能没训到1M或者采用了其他的CP方式（不是单纯的cp2hp的现有方案）
- 算子并行度低。GDN(KDA)的核心算子之一
`chunk_gated_delta_rule_fwd_kernel_h_blockdim64` 目前只能在batch, head和chunk V之间进行并行
 $(N, H, V//BV)$ ，如果batch=1，cp2hp可能导致H也等于1，那么该算子就是灾难级别的，可能只会用到2-4个SM，GPU利用率大大降低。

```
494     def grid(meta): return (triton.cdiv(V, meta['BV']), N*H)
495     chunk_gated_delta_rule_fwd_kernel_h_blockdim64[grid]([

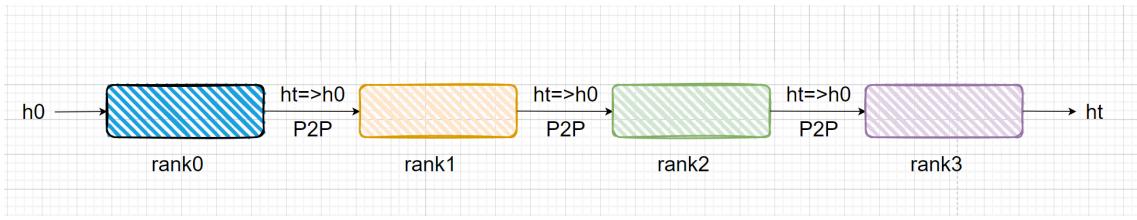
```

- 通信时间长。linear attn的耗时短，cp2hp的通信占比会被放大。



Scan并行算法

- 最简单的方式：GDN(KDA)只有 `chunk_gated_delta_rule_fwd_kernel_h_blockdim64` 这一个算子依赖序列间的信息传递，其他算子都和序列无关。因此一个办法就是逐rank去算，比如rank0先算，得到final_state传给rank1作为initial_state，rank1再算final_state传给rank2.....该方法也很直观，但是gpu之间无法并行计算，rank i需要等待rank i-1算完才能算，会有严重的bubble，类似pp并行的warm up阶段。这显然也不是一个很好的办法。



- 如何解决上述问题？RNN类模型在过去为提高计算效率，将状态(S_t)之间的变化从非线性变化转成线性变化，通过Scan算法可以大幅度提高计算并行度。GDN也可以做类似的事情，只是复杂一些。

Algorithm 1 Parallel linear recurrence on p processors

```

1: Let  $y = [(\Lambda_1, x_1), (\Lambda_2, x_2), \dots, (\Lambda_T, x_T)]$ 
2: Let binary operator  $\bullet$  act as  $(\Lambda, x) \bullet h = \Lambda h + x$ 
3: Let  $S_0 = 1, S_i < E_i, E_i + 1 = S_{i+1}, E_{p-1} = T$  for  $i$  in  $0, p - 1$ 
4:
5: parfor  $i \leftarrow 0, p - 1$  do
6:    $P_i = \text{REDUCE}(\odot, \Lambda_{S_i:E_i}, I)$ 
7:    $R_i = \text{REDUCE}(\bullet, y_{S_i:E_i}, 0)$ 
8: end parfor
9:
10: Let  $z = [(P_0, R_0), (P_1, R_1), \dots, (P_p, R_p)]$ .
11:  $C = \text{SCAN}(\bullet, z, h_0)$                                  $\triangleright$  compute  $C_i = P_i C_{i-1} + R_i$  with  $C_{-1} = h_0$ 
12:
13: parfor  $i \leftarrow 0, p - 1$  do
14:    $h_{S_i:E_i} = \text{SCAN}(\bullet, y_{S_i:E_i}, C_{i-1})$ 
15: end parfor
16: return  $h$ 
  
```

GDN下的Scan算法

前言

本人是阅读博客[DeltaNet如何做序列并行](#)之后才有的想法（之前根本想不到QAQ，建议大家也阅读下原文），并在该基础上进行了进行扩展，推导了GDN和KDA下的并行，以及加上自己的一些理解，对GDN和KDA实现了真正的序列并行。

PS：我数学一般，幸好我只能看懂GDN最后的两个公式，前面的推导看不懂一点，而前面的公式不涉及序列信息的传递，因此可以直接跳过！

$$\mathbf{S}_{[t+1]} = \overrightarrow{\mathbf{S}_{[t]}} + \left(\widetilde{\mathbf{U}_{[t]}} - \overleftarrow{\mathbf{W}_{[t]}} \mathbf{S}_{[t]}^\top \right)^\top \overrightarrow{\mathbf{K}_{[t]}} \in \mathbb{R}^{d_v \times d_k}$$

$$\mathbf{O}_{[t]} = \overleftarrow{\mathbf{Q}_{[t]}} \mathbf{S}_{[t]}^\top + (\mathbf{Q}_{[t]} \mathbf{K}_{[t]}^\top \odot \mathbf{M}) \left(\widetilde{\mathbf{U}_{[t]}} - \overleftarrow{\mathbf{W}_{[t]}} \mathbf{S}_{[t]}^\top \right) \in \mathbb{R}^{C \times d_v}$$

where $\overleftarrow{\mathbf{q}_{[t]}^r} = \gamma_{[t]}^r \mathbf{q}_{[t]}^r$, $\overleftarrow{\mathbf{w}_{[t]}^r} = \gamma_{[t]}^r \mathbf{w}_{[t]}^r$, $\overrightarrow{\mathbf{k}_{[t]}^r} = \frac{\gamma_{[t]}^C}{\gamma_{[t]}^r} \mathbf{k}_{[t]}^r$, and $\overrightarrow{\mathbf{S}_{[t]}} = \gamma_{[t]}^C \mathbf{S}_{[t]}$ like we defined in Eq. 2.

从代码进行切入

假设CP=4，一个完整序列被平均切分为4份。在唯一和序列相关的函数

`chunk_gated_delta_rule_fwd_h`中，每个rank的`initial_state`默认都为0，这对于rank0是对的，对rank1, 2, 3都是错误的，如果有一个额外的函数，能够算出成真实的`initial_state`，那么下面的函数输出的结果就是正确的了。因此我的设计出发点是：写一个额外的函数插入到该函数之前。

```

flash-linear-attention > fla > ops > gated_delta_rule > chunk.py > chunk_gated_delta_rule_fwd
24     def chunk_gated_delta_rule_fwd(
68
69     h, v_new, final_state = chunk_gated_delta_rule_fwd_h(
70         k=k,
71         w=w,
72         u=u,
73         g=g,
74         initial_state=initial_state, ←
75         output_final_state=output_final_state,
76         cu_seqlens=cu_seqlens,
77     )
78

```

反向类似，rank3的dht为0，rank0, 1, 2的dht需要真实的dht，需要一个额外函数算出真实的dht。

```

flash-linear-attention > fla > ops > gated_delta_rule > chunk.py > chunk_gated_delta_rule_bwd
93     def chunk_gated_delta_rule_bwd(          songlin, 12个月前 • [Gated DeltaNet] add kernel
150     dh, dh0, dv = chunk_gated_delta_rule_bwd_dhu(
151         q=q,
152         k=k,
153         w=w,
154         g=g,
155         h0=initial_state,
156         dht=dht, ←
157         do=do,
158         dv=dv,
159         scale=scale,
160         cu_seqlens=cu_seqlens,
161     )

```

前向公式推导

我为了方便写代码，推导过程中的公式的shape和代码中都是一致的，对 S_t 都进行了转置进行表达式。

$$\begin{aligned}
S_{[t+1]}^T &= \overrightarrow{S}_{[t]}^T + \overrightarrow{K}_{[t]}^T(U_{[t]}^T - \overleftarrow{W}_{[t]} S_t^T) \\
&= \overrightarrow{S}_{[t]}^T + K_{[t]}^T(U_{[t]}^T - \overleftarrow{W}_{[t]} S_t^T) \\
&= \gamma_{[t]}^C S_{[t]}^T + K_{[t]}^T \text{diag}(\gamma_{[t]})(U_{[t]}^T - \overleftarrow{W}_{[t]} S_t^T) \\
&= (I \gamma_{[t]}^C - K_{[t]}^T \text{diag}(\gamma_{[t]}) \overleftarrow{W}_{[t]}) S_t^T + K_{[t]}^T \text{diag}(\gamma_{[t]}) U_{[t]}^T
\end{aligned} \tag{1}$$

$$O_{[t]} = \overleftarrow{Q}_{[t]} S_{[t]}^T + (Q_{[t]} K_{[t]}^T \odot M)(U_{[t]}^T - \overleftarrow{W}_{[t]} S_t^T) \tag{2}$$

公式1和2是论文中的两个公式，其中的decay的Q和W我没有展开，是因为这两个与核心算子都无关。在公式1的第二行，K的decay放到了括号那项，这是原始代码中的做法。

$$S_{[t+1]}^{*T} = (I \gamma_{[t]}^C - K_{[t]}^T \text{diag}(\gamma_{[t]}) \overleftarrow{W}_{[t]}) S_{[t]}^{*T} + K_{[t]}^T \text{diag}(\gamma_{[t]}) U_{[t]}^T \tag{3}$$

假设每张rank都初始化 S_0 为0，得到 S_{-t} ，即公式3，这时rank1, 2, 3的结果都是不正确的。

$$S_{[t+1]}^T - S_{[t+1]}^{*T} = (I \gamma_{[t]}^C - K_{[t]}^T \text{diag}(\gamma_{[t]}) W_{[t]})(S_{[t]}^T - S_{[t]}^{*T}) \tag{4}$$

$$S_{[i+k]}^T - S_{[i+k]}^{*T} = \left(\prod_{j=0}^{k-1} (I \gamma_{[i+j]}^C - K_{[i+j]}^T \text{diag}(\gamma_{[i+j]}) W_{[i+j]}) \right) (S_{[t]}^T - S_{[t]}^{*T}) \tag{5}$$

然后用公式1减公式3，得到公式4，对公式4的最后一项继续进行展开，就能得到chunk之间的递推公式5。

$$S_{[i+k]}^T = \left(\prod_{j=0}^{k-1} (I\gamma_{[i+j]}^C - K_{[i+j]}^T \text{diag}(\gamma_{[i+j]}) W_{[i+j]}) \right) (S_{[t]}^T - S_{[t]}^{*T}) + S_{[i+k]}^{*T} \quad (6)$$

$$\begin{aligned} \text{另 } M_{[i]} &= I\gamma_{[i]}^C - K_{[i]}^T \text{diag}(\gamma_{[i]}) W_{[i]} \\ \text{则 } M_{[i+1]} &= (I\gamma_{[i+1]}^C - K_{[i+1]}^T \text{diag}(\gamma_{[i+1]}) W_{[i+1]}) M_{[i]} \end{aligned} \quad (7)$$

对公式5进行移项后得到公式6。

前向算法设计

根据上面的公式，即可设计如下算法。

假设有16个chunk，每张卡4个chunk。

```
rank0: chunk 1, 2, 3, 4, 初始化S*_1=0, M_0=I
rank1: chunk 5, 6, 7, 8, 初始化S*_5=0, M_4=I
rank2: chunk 9, 10, 11, 12, 初始化S*_9=0, M_8=I
rank3: chunk 13, 14, 15, 16, 初始化S*_13=0, M_12=I
```

使用公式1（第2个等号）计算S*，并行算。只需存储一个S，大小为H * K * V

```
rank0: S*_5
rank1: S*_9
rank2: S*_13
rank3: S*_17
```

使用公式7计算M，并行算。只需存储一个M，大小为H * K * K

```
rank0: M_4
rank1: M_8
rank2: M_12
rank3: M_16
```

all_agther。通信量大小为CP * H * K * (K+V)

```
S* = [S*_5, S*_9, S*_13, S*_17]
M = [M_4, M_8, M_12, M_16]
```

使用公式6进行merge，并行算。唯一缺点，该算子，每张卡计算不均衡，但是占比很小

```
rank0: S_1 = 0
rank1: S_5 = S*_5
rank2: S_5 = S*_5, S_9 = M_8 @ S_5 + S*_9
rank3: S_5 = S*_5, S_9 = M_8 @ S_5 + S*_9, S_13 = M_12 @ S_9 + S*_13
```

现在，每个rank都得到有真实的initial_state，继续走GDN的剩余步骤

反向公式推导

反向和前向类似，也可以写成前向的形式，只不过方向是反过来的。算法设计我就不是写了。

另公式1中的： $(U_{[t]}^T - \overleftarrow{W}_{[t]} S_{[t]}^T) = V_1$ ，则 $dV_1 = \text{diag}(\gamma_{[t]}) K_{[t]} dS_{[t+1]}^T$

另公式2中的： $(U_{[t]}^T - \overleftarrow{W}_{[t]} S_t^T) = V_2$ ， dV_2 可以通过其他算子直接求到

对公式1和2中的S_t进行求导。

$$\begin{cases}
 dS_{[t]}^{T(1)} = \overleftarrow{Q}_{[t]}^T dO_{[t]} \\
 dS_{[t]}^{T(2)} = -\overleftarrow{W}_{[t]}^T dV_1 = \overleftarrow{W}_{[t]}^T \text{diag}(\gamma_{[t]}) K_{[t]} dS_{[t+1]}^T \\
 dS_{[t]}^{T(3)} = -\overleftarrow{W}_{[t]}^T dV_2 \\
 dS_{[t]}^{T(4)} = \gamma_{[t]}^C dS_{[t+1]}^T \\
 dS_{[t]}^T = (\gamma_{[t]}^C I - \overleftarrow{W}_{[t]}^T \text{diag}(\gamma_{[t]}) K_{[t]}) dS_{[t+1]}^T + \overleftarrow{Q}_{[t]}^T dO_{[t]} - \overleftarrow{W}_{[t]}^T dV_2 \\
 dS_{[t]}^{*T} = (\gamma_{[t]}^C I - \overleftarrow{W}_{[t]}^T \text{diag}(\gamma_{[t]}) K_{[t]}) dS_{[t+1]}^{*T} + \overleftarrow{Q}_{[t]}^T dO_{[t]} - \overleftarrow{W}_{[t]}^T dV_2 \\
 dS_{[t]}^T - dS_{[t]}^{*T} = (\gamma_{[t]}^C I - \overleftarrow{W}_{[t]}^T \text{diag}(\gamma_{[t]}) K_{[t]})(dS_{[t+1]}^T - dS_{[t+1]}^{*T}) \\
 dS_{[t]}^T - dS_{[t]}^{*T} = (\prod_{j=0}^{k-1} (\gamma_{[t+j]}^C I - \overleftarrow{W}_{[t+j]}^T \text{diag}(\gamma_{[t+j]}) K_{[t+j]}))(dS_{[t+k]}^T - dS_{[t+k]}^{*T}) \\
 dS_{[t]}^T = (\prod_{j=0}^{k-1} (\gamma_{[t+j]}^C I - \overleftarrow{W}_{[t+j]}^T \text{diag}(\gamma_{[t+j]}) K_{[t+j]}))(dS_{[t+k]}^T - dS_{[t+k]}^{*T}) + dS_{[t]}^{*T}
 \end{cases}$$

代码设计

context初始化（最核心）

实际场景中是varlen的，不同rank是可以跳过一些计算的。下面的初始化是最核心的，后面的算子都依赖这些信息，请看下面代码中的注释进行理解。

```

s = cu_seqlens_list[-1]
part_len = (s // world_size)
start, end = part_len * rank, part_len * (rank + 1) # 每个rank的切分范围
def contain(left, right): # 判断该rank的范围与该样本的范围是否重合。
    return (min(right, end) - max(left, start)) > 0
cu_seqlens = []
is_last_rank_list, pre_num_ranks_list, is_first_rank_list, post_num_ranks_list = [], [], [], []
for idx in range(len(cu_seqlens_list) - 1):
    left, right = cu_seqlens_list[idx], cu_seqlens_list[idx + 1]
    if left >= end: # 该样本以及之后的都不会在这个rank范围内
        break
    if contain(left, right):
        cu_seqlens.append(max(left - start, 0))
        pre_num_conv_tokens_list.append(max(0, start - left))
        # cross rank
        if left < start or right > end:
            first_rank = left // part_len
            last_rank = (right - 1) // part_len
            is_last_rank_list.append(rank == last_rank) # forward
            pre_num_ranks_list.append(rank - first_rank) # forward
            is_first_rank_list.append(rank == first_rank) # backward
            post_num_ranks_list.append(last_rank - rank) # backward

```

```

    else:
        is_last_rank_list.append(True)
        pre_num_ranks_list.append(0)
        is_first_rank_list.append(True)
        post_num_ranks_list.append(0)
    if cu_seqlens[-1] != part_len:
        cu_seqlens.append(part_len)
cu_seqlens = torch.tensor(cu_seqlens, dtype=torch.int32,
device=torch.cuda.current_device())
# 取最后一个, 如果是False, 那么该rank需要计算state传给下一个
is_last_rank = is_last_rank_list[-1]
# 取第一个, 如果>0, 需要接收前面rank的state
pre_num_ranks = pre_num_ranks_list[0]
# 取第一个, 如果>0, 需要接收前面rank的conv_tokens
pre_num_conv_tokens = pre_num_conv_tokens_list[0]
# 取第一个, 如果是False, 那么该rank需要计算dstate传给上一个
is_first_rank = is_first_rank_list[0]
# 取最后一个, 如果>0, 需要接收后面rank的dstate
post_num_ranks = post_num_ranks_list[-1]

```

算子

首先 `pre_process_fwd_kernel_stage1` 直接 copy fla 的算子

`chunk_gated_delta_rule_fwd_kernel_h_blockdim64`, 对其进行删删减减即可, 非常easy。注意grid是没有batch这个维度的, 如果是varlen, 该rank的batch数量比较大, 那么该算子的耗时非常短。

然后 `pre_process_fwd_bwd_kernel_stage2` 是对公式6进行实现。该grid是没有batch这个维度的。这个算子有个缺点, 公式中6中有个 $K_T @ W$, 并且还需要连乘, 因为K和W的head_dim维度没法拆开, 因此head_dim目前最大只可以是128, 如果是192和256算子都跑不通。为了提高并行度, 可以在每个sm 初始化 M_0 的时候, 只初始化 $[K, K//BK2]$ 的大小, 这样 $K_T @ W$ 的计算都是重复的, 但是 $M_{j+1} = (*) @ M_j$ 的计算量可以变小。

接着进行 `all_gather` 通信, 通信量和CP的大小成正比

最后 `merge_fwd_bwd_kernel` 会更新该rank的第一个样本的 `initial_state`

反向和前向一样, 只是 `pre_process_fwd_kernel_stage1` 换成了 `pre_process_bwd_kernel_stage1`, 是对 `chunk_gated_delta_rule_bwd_kernel_dhu_blockdim64` 进行删删减减

```

def chunk_gated_delta_rule_fwd_h_pre_process(*):
    hm = k.new_zeros(H, K, (V + K), dtype=DTYPE)
    initial_state = k.new_zeros(N, H, K, V, dtype=DTYPE)

    if not context.is_last_rank:
        def grid(meta): return (triton.cdiv(V, meta['BV']), H)
        pre_process_fwd_kernel_stage1[grid](hm, cu_seqlens=cu_seqlens[-2:], *)
        def grid(meta): return (triton.cdiv(K, meta['BK2']), H)
        pre_process_fwd_bwd_kernel_stage2[grid](hm, cu_seqlens=cu_seqlens[-2:], *)
    ag_hm, _ = all_gather(hm, group=context.group)

    if context.pre_num_ranks > 0:
        def grid(meta): return (triton.cdiv(V, meta['BV']), H)

```

```
merge_fwd_bwd_kernel[grid](initial_state[0], rank, pre_num_ranks, *)  
  
return initial_state
```

接入带GDN或者KDA中

首先初始化context

```
flash-linear-attention > fla > layers > gated_deltanet.py > ...  
322     class GatedDeltaNetWithCP(GatedDeltaNet):  
323         def forward(  
324             ...  
325             set_gdn_cp_context(cu_seqlens, self.group, kernel_size=self.conv_size if self.use_short_conv else None)  
326             context = get_gdn_cp_context()  
327  
328             ...  
329             kwargs['cu_seqlens'] = context.cu_seqlens  
330             out = super().forward(  
331                 ...  
332                 hidden_states,  
333                 attention_mask,  
334                 past_key_values,  
335                 use_cache,  
336                 output_attentions,  
337                 **kwargs,  
338             )  
339             kwargs['cu_seqlens'] = cu_seqlens  
340  
341         return out  
342  
343
```

forward中进行插入

```
flash-linear-attention > fla > ops > gated_delta_rule > chunk.py > chunk_gated_delta_rule_fwd  
24     def chunk_gated_delta_rule_fwd(  
25         songlin, 12个月前 • [Gated DeltaNet] add kernel  
26         context = get_gdn_cp_context()  
27         initial_state = chunk_gated_delta_rule_fwd_h_pre_process(  
28             k=k,  
29             w=w,  
30             u=u,  
31             g=g,  
32             cu_seqlens=cu_seqlens,  
33             initial_state=initial_state,  
34             context=context,  
35         )  
36  
37         h, v_new, final_state = chunk_gated_delta_rule_fwd_h(  
38             k=k,  
39             w=w,  
40             u=u,  
41             g=g,  
42             initial_state=initial_state,  
43             output_final_state=output_final_state,  
44             cu_seqlens=cu_seqlens,  
45         )  
46  
47
```

backward中进行插入

```

flash-linear-attention > fla > ops > gated_delta_rule > chunk.py > chunk_gated_delta_rule_bwd
93     def chunk_gated_delta_rule_bwd(          songlin, 12个月前 · [Gated DeltaNet] add kernel
135
136         dht, initial_state = chunk_gated_delta_rule_bwd_dhu_pre_process(
137             q=q,
138             k=k,
139             w=w,
140             do=do,
141             dv=dv,
142             g=g,
143             scale=scale,
144             cu_seqlens=cu_seqlens,
145             dht=dht,
146             initial_state=initial_state,
147             context=context,
148         )
149
150     dh, dh0, dv = chunk_gated_delta_rule_bwd_dhu(
151         q=q,
152         k=k,
153         w=w,
154         g=g,
155         h0=initial_state,
156         dht=dht,
157         do=do,
158         dv=dv,
159         scale=scale,
160         cu_seqlens=cu_seqlens,
161     )

```

注意的是，如果用到的conv1d，还需要拿到上一个rank的尾块token，需要进行额外的通信。可恶的conv1d，什么时候去死！

```

flash-linear-attention > fla > modules > convolution.py > ShortConvolution
806 class ShortConvolution(nn.Conv1d):      Yu Zhang, 21个月前 · More readable infos ...
901     def forward(
902         self,
903             x, cu_seqlens = pre_process_for_conv1d(x, cu_seqlens)
904             y, cache = causal_conv1d(
905                 x=x,
906                 weight=rearrange(self.weight, "d 1 w -> d w"),
907                 bias=self.bias,
908                 residual,
909                 initial_state=cache,
910                 output_final_state=output_final_state,
911                 activation=self.activation,
912                 backend=self.backend,
913                 cu_seqlens=cu_seqlens,
914                 chunk_indices=chunk_indices,
915                 **kwargs,
916             )
917             y = post_process_for_conv1d(y, T)
918             return y, cache
919
920
921
922
923
924
925
926
927
928
929
930
931
932
933
934
935
936
937
938
939
940
941
942
943
944
945
946
947
948
949
950
951
952
953
954
955
956
957
958
959
960
961
962
963
964
965
966
967
968
969
970
971
972
973
974
975
976
977
978
979
980
981
982
983

```

性能表现

32k, cp=4, num_head=64, head_dim=128。torch=2.8, cuda=12.8, triton=3.4, gpu=H800。

3种模式，全量，a2a模式(包含通信，但是每张卡head变少)，以及本文所讲的CP方式。只对比了核心chunk函数，不包含linear和conv1d等操作。

据一位朋友告知：256k下，训练类似kimi-linear的模型，端到端可加速20%，money大大的省！

```

cu_seqlen: [0, 32768]

GDN forward
custom cp, non-cp time: 5.432 ms, cp time: 2.160 ms, rate: 62.86 %
all to all, non-cp time: 5.432 ms, cp time: 4.068 ms, rate: 33.38 %

GDN forward + backward
custom cp, non-cp time: 16.516 ms, cp time: 5.878 ms, rate: 70.24 %
all to all, non-cp time: 16.516 ms, cp time: 10.592 ms, rate: 38.98 %

KDA forward
custom cp, non-cp time: 7.753 ms, cp time: 2.622 ms, rate: 73.93 %

```

```

all to all, non-cp time: 7.753 ms, cp time: 5.047 ms, rate: 38.41 %

KDA forward + backward
custom cp, non-cp time: 37.592 ms, cp time: 10.801 ms, rate: 87.01 %
all to all, non-cp time: 37.592 ms, cp time: 15.877 ms, rate: 59.19 %

长文本训练种也包含一些短文本
cu_seqlen: [0, 2960, 5212, 9513, 13567, 17443, 20634, 23521, 26281, 31785, 32768]

GDN forward
custom cp, non-cp time: 4.816 ms, cp time: 1.665 ms, rate: 72.31 %
all to all, non-cp time: 4.816 ms, cp time: 3.460 ms, rate: 34.80 %

GDN forward + backward
custom cp, non-cp time: 15.815 ms, cp time: 4.897 ms, rate: 80.74 %
all to all, non-cp time: 15.815 ms, cp time: 8.608 ms, rate: 45.93 %

KDA forward
custom cp, non-cp time: 8.066 ms, cp time: 2.351 ms, rate: 85.76 %
all to all, non-cp time: 8.066 ms, cp time: 4.750 ms, rate: 42.45 %

KDA forward + backward
custom cp, non-cp time: 37.730 ms, cp time: 10.489 ms, rate: 89.93 %
all to all, non-cp time: 37.730 ms, cp time: 15.162 ms, rate: 62.21 %

```

profile分析

以KDA前向为例，拿的rank2的timeline信息

可以看到本文介绍的cp方式比cp2hp的方式要友好很多，主要原因是all2all的时间占比很大

下面是cu_seqlens=[0, 32768]



本文cp多了3个算子+一次通信，然后 `chunk_gated_delta_rule_fwd_kernel_h_blockdim64` 大概耗时300us左右

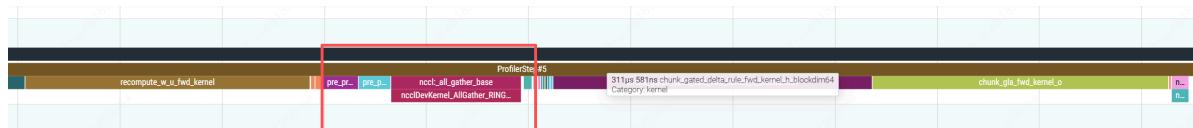


cp2hp中，`chunk_gated_delta_rule_fwd_kernel_h_blockdim64` 大概耗时800us左右，因为head变少，并行度降低，效率大大折扣



下面是cu_seqlens=[0, 2960, 5212, 9513, 13567, 17443, 20634, 23521, 26281, 31785, 32768]

本文cp，可以看到因为单个rank的样本数增加，我们只需要算一个样本即可，因此前2个算子时间大大减少，通信时间不变



cp2hp，样本数增加，并行度增加，因此时间也会减少一些。

